



SignalMod

Search comments...



Sign in

Home

Shorts

Subscriptions

Library

History

Your videos

Moderation

Moderación inteligente para YouTube.

Detección automática de mensajes de odio en comentarios,
diseñada para escalar al ritmo de la plataforma.


► **Sign in**

Learn more



How SignalMod works

Demo · 1:24 · SignalMod



El desafío de la toxicidad

500M+

comentarios al día

En YouTube global

~12%


contienen toxicidad

Insultos, amenazas, odio

∞

capacidad humana

El equipo no da abasto



↓ más comentarios...

«Se requiere una solución práctica que escale al ritmo de la plataforma.»

— Briefing del cliente, YouTube

¿Qué es SignalMod?

Un asistente de moderación inteligente para comentarios de YouTube



SignalMod clasifica cada comentario como Seguro o Tóxico

Devuelve una probabilidad de 0 a 1 y etiquetas de categoría:

- Insulto
- Amenaza
- Odio identitario
- Contenido obsceno



API REST

Integrable con cualquier herramienta interna

POST /predict

POST /batch

POST /video



Interfaz Web

Simula la experiencia de YouTube Watch

- Vista tipo «Watch»
- Badges Seguro / Tóxico por comentario
- Cambio de modelo desde Settings



Cómo se siente usarlo

Tres pasos. Mismo lenguaje visual que YouTube.

1 · Watch

Eliges un vídeo

Del rail de sugeridos.



2 · Score

La API puntúa los comentarios

~50 ms por comentario.



3 · Settings

Cambias el modelo activo

Sin redeploy.

Meta-Stack (Production) • activo

F1 0.805 · gap 2.54pp

Frozen Toxic-BERT ○

F1 0.790 · gap 0.16pp

LR + TF-IDF (Baseline) ○

F1 0.758 · ~50ms

¿Quién lo usa?

Cuatro perfiles, una misma cola de moderación más manejable.



Moderador de YouTube

Prioriza la cola: primero los comentarios con probabilidad alta de toxicidad.



Creador de contenido

Filtra automáticamente la bandeja antes de revisarla.



Comunidad / foros

Aviso temprano cuando un hilo se está envenenando.



Investigación / docencia

Estudio comparado de discurso de odio sobre un corpus.

Stack tecnológico

Una solución práctica, no un zoo de dependencias.

Capa de datos

Dataset + EDA

youtoxic_english_1000.csv · 1 000 filas · IsToxic

pandas · matplotlib

seaborn · scikit-learn

NLP

Preprocesado + vectorización

Regex + spaCy + NLTK + TF-IDF + BoW

spaCy · NLTK

regex · nlpaug

Modelado

Modelos + tuning

LR · RF · XGBoost · Optuna · HF transformers

Optuna · XGBoost

transformers · torch

Servicio

API + UI

FastAPI sirve JSON y el SPA construido.

FastAPI · Uvicorn

React 18 · Vite + TS

Operación

Docker + tracking

Un contenedor sirve API + SPA. MLflow.

Docker · compose

MLflow · uv

Datos externos


YouTube Data API v3

Descarga comentarios reales por URL.

httpx · API key

Arquitectura del modelo

Hybrid Meta-Feature Stacking — dos ramas, un solo meta-learner.



Por qué funciona en 1k filas

BERT da semántica sin fine-tune. Los metadatos aportan estructura interpretable. LR los combina.

Reproducible

```
uv run python -m src.experiments.notebook_14_final_stack  
Genera meta_stack_final.joblib
```

Dataset y EDA

1 000 comentarios reales. Equilibrado pero pequeño.

1 000

comentarios

youtoxic_english_1000.csv

53.8%

Seguros

538 ejemplos

46.2%

Tóxicos

462 ejemplos

200

test split

80/20 estratificado

Lo que nos contó el EDA



Sesgo temático — noticias concretas (caso Ferguson) dominan parte del corpus.



Multietiqueta dispersa — pocos positivos por clase → trabajamos binario sobre IsToxic.



Vocabulario identitario — «black», «white», «police» aparecen tanto en tóxicos como en debate informativo.

Modelos del catálogo

Tres modelos, todos evaluados sobre el mismo test split.

Modelo	Tipo	F1 test	Gap T-T	Umbral	Latencia	Default
Meta-Feature Stacking	Hybrid	0.805	2.54 pp	0.381	~400ms	YES
Frozen Toxic-BERT	Transformer	0.790	0.16 pp	0.12	~400ms	—
LR + TF-IDF	sklearn	0.758	4.76 pp	0.50	<50ms	—

Métricas reproducibles en `models/baseline/manifest.json` y `reports/notebook_14/`

Por qué Meta-Stack es producción

Mejor F1 del catálogo · cumple criterio gap < 5pp · supera el objetivo $F1 \geq 0.80$ · interpretable.

El meta-learner

Cómo se combinan las dos ramas en el modelo de producción.

Features de entrada

bert_cls_embedding	768-d
comment_length	int
uppercase_ratio	float 0-1
emoji_density	float

Meta-learner ganador

Notebook 14 · meta_stack_final

model	LogisticRegression
C (regularization)	0.001
scaler	Standard
threshold	0.381
F1 (test)	0.805

Artefacto

models/production_final/meta_stack_final.joblib

Métricas en producción

200 muestras de test · Meta-Feature Stacking.

0.805

F1 ponderado

supera objetivo 0.80 ✓

2.54 pp

Brecha train-test

< 5 pp ✓

0.381

Umbral óptimo

balance FP/FN

~400ms

Latencia

CPU · BERT embedding

Comparativa contra baselines

	F1	Gap
LR + TF-IDF	0.758	4.76 pp
Frozen Toxic-BERT	0.790	0.16 pp
Meta-Stack (prod)	0.805	2.54 pp

Criterio de generalización

Regla del equipo: $|F1 \text{ train} - F1 \text{ test}| < 5 \text{ pp}$.

✓ 2.54	Meta-Stack · margen 2.46 pp bajo el límite
✓ 0.16	Frozen BERT · sin fine-tune, gap mínimo
✓ 4.76	LR baseline · justo bajo el límite

Análisis de errores

Dónde se equivoca el modelo, y por qué.

18 FP Falsos positivos

Seguros marcados como tóxicos. Tokens frecuentes:

black · 14

would · 9

white · 9

shoot · 8

cop · 6

police · 5

Patrón: debate político y noticias sobre brutalidad policial. El modelo aprende correlaciones del corpus, no opiniones.

30 FN Falsos negativos

Tóxicos no detectados. Tokens frecuentes:

police · 8

make · 6

criminal · 6

black · 6

people · 5

kill · 5

Patrón: toxicidad indirecta, sarcasmo o textos largos donde la señal se diluye.

El catálogo de modelos

Tres opciones intercambiables desde la UI. POST /models/select.



Meta-Stack (Production)

models/production_final/meta_stack_final.joblib

F1 0.805

~400ms

hybrid



Frozen Toxic-BERT

unitary/toxic-bert

F1 0.790

~400ms

hf_remote



LR + TF-IDF

models/baseline/lr_tfidf.joblib

F1 0.758

<50ms

local



Umbral por modelo

ajustable desde Settings

0.12-0.50

—

config

Cambio en caliente

El usuario cambia de modelo desde Settings sin redeploy. Banner en la UI muestra el modelo activo y sus métricas.

Persistencia y comentarios reales

Cada predicción se guarda. Cada vídeo trae sus comentarios reales.

DB Supabase

PostgreSQL gestionado · políticas RLS abiertas


- Cada predicción se persiste en predictions (texto, vídeo, probabilidad, modelo, timestamp).
- Cualquier visitante puede dejar un comentario; aparece en «Recent activity» para todos.
- Endpoint GET /predictions para histórico filtrable por video_id.

```
POST /predict → save_prediction()  
GET /predictions?video_id=...
```

LIVE Comentarios reales

YouTube Data API v3 · 50 últimos por vídeo

- commentThreads.list ordenado por time → los 50 más recientes.
- Cada uno se clasifica al vuelo (SAFE / TOXIC
1. probabilidad + categorías).
- Locales (Supabase) arriba, YouTube debajo — en una sola lista cronológica.



Cobertura del briefing

Cuatro niveles. Honestidad sobre lo entregado.

ESENCIAL 4 / 4

- ✓ Modelo ML detecta odio (F1 0.805)
- ✓ Overfit 2.54 pp · margen 2.46 pp
- ✓ API + UI productivizadas
- ✓ Git con ramas + README ES/EN

MEDIO 4 / 4

- ✓ Ensemble (Meta-Stack producción)
- ✓ Análisis por enlace de vídeo
- ✓ Tests unitarios (pytest)
- ✓ Tuning con Optuna (baseline LR)

AVANZADO 1 / 4

- × RNN/LSTM (saltamos a transformers)
- × Tiempo real · × Despliegue público
- ✓ Dockerización (compose + multi-stage)

EXPERTO 3 / 3

- ✓ Transformers (Frozen Toxic-BERT)
- ✓ Stack híbrido sobre embeddings BERT
- ✓ BD de predicciones (Supabase)
- ✓ MLflow (tracking integrado)

Trabajo futuro

Roadmap honesto, mapeado al briefing.

Alta Más datos etiquetados

Reducir FP en debate político/racial. Mejorar recall en toxicidad implícita.

Alta Ajuste de umbral

Optimizar el umbral 0.5 sobre validación para alinear FP/FN con la política del cliente.

Media Tiempo real (WebSocket)

/ws/video/{id} con polling de la YouTube API. Nivel avanzado del briefing.

Media BD de predicciones

PostgreSQL + SQLAlchemy. predictions(id, text, prob, model, ts). Nivel experto.

Baja LSTM como baseline

torch.nn.LSTM sobre embeddings preentrenados, comparado contra LR.

Baja Despliegue público

Render / Fly.io + GitHub Actions CI/CD. HTTPS automático.

El equipo

Cuatro perfiles construyendo SignalMod.




Roberto Molero

Product Owner




Mirae Kang

Scrum Master



Jonathan Brasales

AI Developer



Andrés Torrez

Backend Developer

Equipo multidisciplinar

De la visión de producto al modelo, de la API a la interfaz: SignalMod es el resultado de un trabajo coordinado donde cada decisión técnica responde a una necesidad real del cliente.

SignalMod



Gracias.

¿Hablamos?

SignalMod está listo para integrarse en cualquier flujo de moderación. Roadmap completo a disposición del cliente.